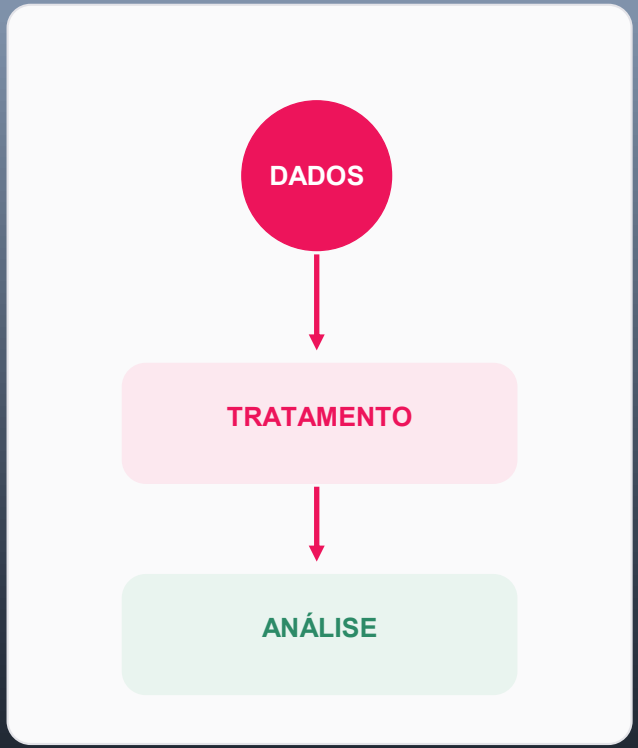
Pipeline de Alfabetização
Arquitetura Medalhão

Tech Challenge – Fase 2

Eric Schwinn Lima



Repositório do projeto

github.com/Eric-Schwinn-Lima/Tech-Challenge-Pipeline-Fase-2

O desafio: transformar dados dispersos em informação útil

A alfabetização até o final do 2º ano do Ensino Fundamental é um marco importante para a trajetória escolar. Para acompanhar esse resultado, existem dados de desempenho, metas e informações territoriais publicados em diferentes conjuntos.

O projeto cria um caminho organizado para integrar essas fontes, conferir sua consistência e disponibilizar os dados para análise.

A pergunta central

Onde estamos, como evoluímos e onde é preciso concentrar esforços?

O dado está distribuído em diferentes bases

O pipeline reúne seis entidades de dados e um dicionário auxiliar para interpretar os códigos da fonte.

UF

Resultados por unidade da federação

MUNICÍPIO

Resultados e vínculo com o estado

METAS

Brasil, estados e municípios

ALUNOS

Microdados de desempenho

DICIONÁRIO

Descrição de códigos e categorias

O que muda depois da integração?

As informações passam a compartilhar chaves e categorias padronizadas, permitindo relacionar território, resultado e meta.

Critérios para Desenvolvimento da Aplicação

Ingestão Híbrida

Dois caminhos de entrada: arquivos processados em lotes e eventos simulados recebidos individualmente.

Arquitetura Medalhão

Dados separados em três níveis: bronze, silver e gold.

Validação

Regras de qualidade verificam os dados antes de liberar as tabelas para consulta.

Disponibilidade

Tabelas estruturadas e consultáveis para análises educacionais e projetos futuros de IA.

Sair de arquivos isolados para uma base organizada, rastreável e pronta para consulta

Como os dados percorrem a solução

Dois caminhos de entrada convergem para uma área comum de armazenamento, tratamento e análise.



ORQUESTRAÇÃO	Coordena o processamento, as atualizações do catálogo e a validação final.
MONITORAMENTO	Registra logs, métricas e alertas para acompanhar a operação.

Ingestão: Dois caminhos, necessidades diferentes

Batch: arquivos em lotes

1. Recebe as seis entidades públicas e o dicionário auxiliar.
2. Preserva os arquivos recebidos e prepara versões padronizadas.
3. Processa o conjunto de dados e cria novas saídas identificadas por execução.

ARQUIVOS CSV Processamento da base completa, com histórico e possibilidade de reexecução.

Streaming

1. Um evento de demonstração é enviado individualmente.
2. A fila recebe a mensagem e uma função processa o conteúdo.
3. O evento é armazenado, validado e pode chegar à tabela analítica.

SIMULAÇÃO SQS + LAMBDA Um evento sintético foi encontrado na Gold na execução integrada.

Arquitetura Medalhão

A separação em três níveis mantém a origem rastreável, simplifica os tratamentos e prepara os dados para análise.

Bronze

Dados Brutos

Arquivos originais, arquivos preparados e eventos armazenados sem misturar sua origem.

Por quê? Preserva o histórico e permite reprocessar quando as regras mudam.

ORIGEM

Silver

Dados tratados

Campos e tipos padronizados, chaves normalizadas, valores verificados e bases integradas.

Por quê? Cria uma estrutura consistente para as análises.

TRATAMENTO

Gold

Dados analíticos

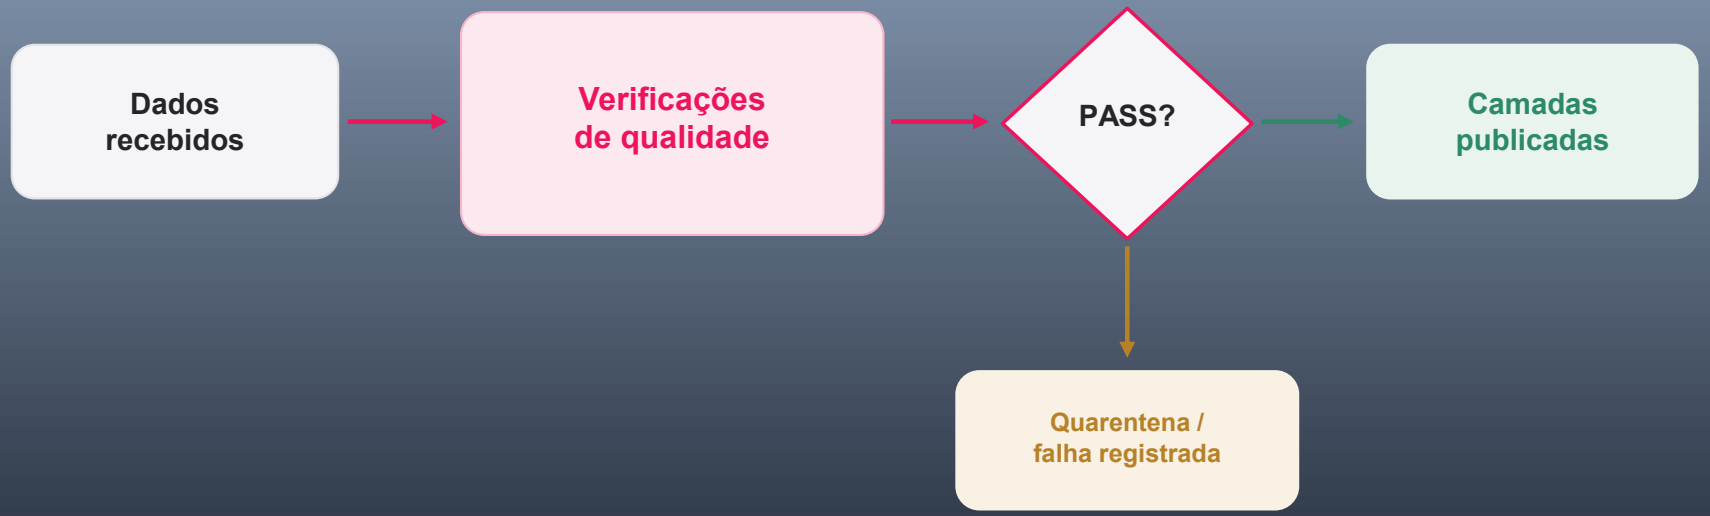
Produtos analíticos para municípios, estados, metas, evolução, proficiência, reconciliação e eventos.

Por quê? Facilita consultas e análises de negócio.

ANÁLISE

Qualidade antes de liberar a análise

O fluxo não deve apenas transformar dados: precisa verificar se eles estão consistentes e bloquear falhas críticas.



O que é conferido

- ✓ Estrutura e campos obrigatórios
- ✓ Valores ausentes e duplicidades
- ✓ Faixas válidas e chaves de relacionamento
- ✓ Correspondência entre as bases integradas

Eficiência, monitoramento e controle

As escolhas de implementação buscam evitar processamento ocioso, reduzir leitura desnecessária e limitar retenção.

Escolha	Alternativa	Benefício buscado
Dois workers G.1X	Cluster fixo maior	Dimensiona o processamento ao volume observado.
Parquet + Snappy	CSV/JSON para consulta	Formato colunar e comprimido; facilita ler somente o necessário.
SQS + Lambda	Consumidor permanente	Recebe eventos sob demanda; consumidor fica desativado fora dos testes.
Retenção controlada	Guardar tudo indefinidamente	Versões não correntes do S3: 90 dias; logs dedicados: 30 dias.

Monitoramento

Logs de Glue e Lambda com retenção de 30 dias; alarme de erro e métricas de eventos.

O que essa base permite fazer

As tabelas estruturadas podem apoiar análises educacionais agora e servir de ponto de partida para modelos de IA futuros.

Enxergar desigualdades

Comparar resultados entre estados, municípios e redes para encontrar padrões e diferenças regionais.

Apoiar decisões

Ajudar a priorizar análises e ações onde os indicadores mostram maior necessidade de acompanhamento.

Obrigado!

Eric Schwinn Lima Tech Challenge Fase 2

Repositório: github.com/Eric-Schwinn-Lima/Tech-Challenge-Pipeline-Fase-2